



PRÉDICTION DE LA QUALITÉ DE L'AIR AU CAMEROUN

Rapport méthodologique

Équipe :

- ● ● ● Manuel Gires PANDO KOMBOU
- ● ● ● Reine Vertu KOKOLO MBOUSSI
- ● ● ● Shun Aucel MBAKOP BANKINIEN
- ● ● ● Espoir TSIA NGUIABESSA

Remerciement :

- ● ● ● Jonathan Patrick ZE II

AirEka

Plateforme de Prévision de la Qualité de l'Air
au Cameroun, 40 Villes, 10 Régions

Rapport Méthodologique Complet

Équipe **DeepStats** · IndabaX Cameroon 2026

À propos du nom AirEka

Le nom **AirEka** est une fusion intentionnelle. Il s'inspire du célèbre cri « *Eureka* ! » d'Archimède; cette exclamation de la découverte soudaine, et du mot *Eka*, qui en langue locale camerounaise (Beti) signifie « **garde** » ou « **protection** ».

AirEka est donc littéralement : « *J'ai trouvé comment protéger* ! » ; une plateforme née d'une démarche scientifique rigoureuse, au service de la santé des populations camerounaises.

Ce document retrace intégralement l'approche de l'équipe DeepStats, depuis la conception de la variable cible jusqu'au déploiement d'une application web complète couvrant 40 villes des 10 régions du Cameroun.

Partie I — Approche Méthodologique | **Partie II** — Architecture Technique de l'Application AirEka

Table des matières

1	Contexte et Problématique	3
1.1	Pourquoi prédire plusieurs polluants et non un seul ?	3
2	Collecte et Constitution de la Base de Données	4
2.1	Données météorologiques fournies par les organisateurs	4
2.2	Enrichissement par scraping : deux sources complémentaires	4
2.3	Agrégation journalière conforme aux normes EPA	5
3	Calcul de l’Air Quality Index (AQI)	5
3.1	Exemple de calcul — Abong-Mbang, 3 janvier 2020	5
4	Ingénierie des Variables (Feature Engineering)	6
5	Modélisation et Apprentissage Automatique	7
5.1	Transformation logarithmique : une décision critique	7
5.2	Stratégie de split temporel strict	7
5.3	Algorithmes et ensemble final	7
6	Résultats des Modèles	8
7	Détection et Correction des Leakages	8
7.1	Leakage 1 : <code>diff()</code> sur les valeurs courantes	8
7.2	Leakage 2 : <code>city_stats</code> calculées sur tout le dataset	9
7.3	Leakage 3 : Split aléatoire sur séries temporelles	9
8	Intervalles de Confiance : Conformal Prediction	9
9	Pipeline de Prédiction Opérationnel	9
10	Architecture Globale de l’Application	11
11	Système d’Authentification et Gestion des Utilisateurs	11
12	Dashboard Principal et Système de Routage	12
13	Pages Spécialisées par Profil Utilisateur	12
13.1	Dashboard Citoyen (<code>citizen_pages.py</code>)	12
13.2	Dashboard Décideur (<code>decision_maker_pages.py</code>)	12
13.3	Dashboard Chercheur (<code>researcher_pages.py</code>)	13
14	Chatbot IA et Interprétation Contextuelle	13
15	Système d’Alertes Email Automatiques (<code>email_scheduler.py</code>)	13
15.1	Alertes citoyennes : quotidiennes	13
15.2	Alertes décideurs : hebdomadaires (lundi 08h00)	13
15.3	Configuration technique Gmail	14
16	API de Prédiction : Architecture et Endpoints	14
17	Stack Technologique Complète	15
A	Tables complètes des paliers EPA	16

Références Bibliographiques

18

PARTIE I — Approche Méthodologique

Cette partie détaille la chaîne complète : collecte des données atmosphériques, calcul de l'AQI, ingénierie des variables, modélisation par gradient boosting, gestion des leakages et prédiction opérationnelle.

1. Contexte et Problématique

Le Cameroun, avec ses 30,06 millions d'habitants en 2026 selon des estimations, répartis entre zones urbaines denses et régions rurales traversées par l'Harmattan, présente une diversité climatique et atmosphérique qui influe directement sur la qualité de l'air. Pourtant, aucun système opérationnel d'alerte précoce à la pollution atmosphérique n'existait au moment du lancement du projet IndabaX 2026.

L'équipe DeepStats a choisi de répondre à ce défi en concevant un **pipeline complet**, de la collecte des données brutes jusqu'à la prédiction en temps réel et la diffusion d'alertes.

La particularité de ce hackathon résidait dans la nature des données fournies : le dataset initial ne contenait que **18 variables météorologiques journalières** pour 40 villes, sans aucune mesure de polluants atmosphériques. C'est cette contrainte fondamentale qui a conduit l'équipe à une démarche innovante de scraping autonome de sources satellitaires, détaillée en section 2.

1.1 Pourquoi prédire plusieurs polluants et non un seul ?

La première décision structurante a été de **rejeter l'approche naïve** consistant à prédire un seul polluant (PM_{2,5} par exemple). Chaque polluant agit sur des organes différents et présente des seuils de danger propres : le CO provoque l'asphyxie, le NO₂ aggrave l'asthme, l'O₃ réduit la capacité pulmonaire, le SO₂ génère des bronchospasmes. Un décideur sanitaire ne peut pas interpréter directement « 53,86 µg/m³ de PM_{2,5} » sans référentiel contextuel.

La solution adoptée : l'**Air Quality Index (AQI)**, indice composite de l'US EPA agréant six polluants en un score de 0 à 500, immédiatement interprétable par tous les publics — du citoyen au décideur politique.

Table 1. Polluants du dataset, seuils OMS 2021 et profil de risque camerounais.

Polluant	Seuil OMS	Pathologie principale	Profil de risque au Cameroun
PM _{2,5}	$\leq 5 \mu\text{g}/\text{m}^3$	Cancer poumon, AVC, infarctus	<i>Dominant.</i> Feux de biomasse, Harmattan chargé. 76 % des jours dépassent le seuil OMS.
PM ₁₀	$\leq 15 \mu\text{g}/\text{m}^3$	Bronchite, rhinite, conjonctivite	Poussières sahariennes (Harmattan, Extrême-Nord, janv.–mars).
NO ₂	$\leq 10 \mu\text{g}/\text{m}^3$	Asthme chronique, BPCO	Trafic motorisé et groupes électrogènes à Douala et Yaoundé.
O ₃	$\leq 60 \mu\text{g}/\text{m}^3$	Douleur thoracique, lésions pulmonaires	Polluant secondaire (photolyse UV). Fort ensoleillement camerounais.
CO	$\leq 4000 \mu\text{g}/\text{m}^3$	Asphyxie, troubles cardiaques	Combustion incomplète de biomasse (cuisson au bois). Pics à $17\,178 \mu\text{g}/\text{m}^3$.
SO ₂	$\leq 40 \mu\text{g}/\text{m}^3$	Bronchospasme, pluies acides	Industrie pétrolière (Limbé, Kribi) et groupes électrogènes diesel.

2. Collecte et Constitution de la Base de Données

2.1 Données météorologiques fournies par les organisateurs

Le dataset initial fourni par les organisateurs de l'IndabaX Cameroon 2026 regroupe **18 variables météorologiques journalières** pour 40 villes camerounaises sur la période du 01/01/2025 au 20/12/2025, soit **87 240 observations** au total. Ces variables couvrent : les températures maximale, minimale et moyenne (réelles et ressenties), les précipitations (somme, heures), la durée d'ensoleillement, le rayonnement global (shortwave), la vitesse et direction du vent, et l'évapotranspiration de référence FAO.

Particularité cruciale

Aucune donnée de qualité de l'air n'était incluse dans ce dataset. C'est l'obstacle central que l'équipe DeepStats a dû surmonter par une démarche de scraping autonome décrite ci-après.

2.2 Enrichissement par scraping : deux sources complémentaires

Stratégie de collecte : deux sources satellitaires complémentaires

Source 1 — CAMS EAC4 (Copernicus ADS) : période 2020-01-01 → 2022-08-07, format NetCDF, 8 observations 3-horaires/jour, via l'API Python `cdsapi`.

Source 2 — Open-Meteo Air Quality API : période 2022-08-08 → 2025-12-31, données horaires JSON, gratuites sans clé API, via requêtes REST.

Stratégie de priorité : Open-Meteo est source principale. CAMS EAC4 comble les lacunes historiques.

Open-Meteo Air Quality API fournit des séries horaires pour PM_{2,5}, PM₁₀, NO₂, O₃, CO et SO₂ basées sur les modèles CAMS de Copernicus. La collecte est réalisée ville par ville, par

segments annuels pour éviter les timeouts, avec un mécanisme de retry exponentiel et un système de checkpoint (sauvegarde Parquet intermédiaire).

CAMS EAC4 (Copernicus Atmosphere Monitoring Service, réanalyse EAC4) est interrogé via la bibliothèque Python `cdsapi`. Les fichiers NetCDF contiennent deux couches : `data_sfc.nc` (PM_{2,5}, PM₁₀) et `data_mlev.nc` (NO₂, O₃, CO, SO₂). Une détection automatique du format et une sélection du point de grille le plus proche (méthode *nearest*) sont implémentées.

2.3 Agrégation journalière conforme aux normes EPA

Les données horaires brutes sont agrégées en valeurs journalières selon les règles officielles de l'US EPA (*EPA-454/B-24-002, 2024*), qui diffèrent selon la nature physique de chaque polluant :

Table 2. Règles d'agrégation EPA et approximations appliquées sur CAMS EAC4.

Polluant	Règle EPA	Approximation CAMS (3h)
PM _{2,5} , PM ₁₀	Moyenne sur 24 h	Moyenne des 8 observations 3-horaires
NO ₂ , SO ₂	Maximum sur 1 h (norme court terme)	Maximum des 8 obs.
O ₃ , CO	Max des fenêtres glissantes 8 h	Max fenêtre glissante 3 obs. (~9h, proxy 8h)

3. Calcul de l'Air Quality Index (AQI)

L'AQI est un indice adimensionnel sur l'intervalle 0–500, publié par l'US EPA depuis 1976 et révisé en *février 2024* (*EPA-454/B-24-002*). Il convertit chaque concentration polluante en un sous-indice via une interpolation linéaire par paliers, puis retient le maximum comme score global de qualité de l'air.

Formule officielle AQI : US EPA 2024

$$AQI_{\text{polluant}} = \frac{AQI_{\text{max}} - AQI_{\text{min}}}{C_{\text{max}} - C_{\text{min}}} \times (C - C_{\text{min}}) + AQI_{\text{min}}$$

$$AQI_{\text{final}} = \max(AQI_{\text{PM}_{2,5}}, AQI_{\text{PM}_{10}}, AQI_{\text{NO}_2}, AQI_{\text{O}_3}, AQI_{\text{CO}}, AQI_{\text{SO}_2})$$

Où C = concentration mesurée ; $C_{\text{min}}/C_{\text{max}}$ = bornes du palier de concentration ; $AQI_{\text{min}}/AQI_{\text{max}}$ = valeurs d'indice correspondantes.

Table 3. Grille d'interprétation de l'AQI (US EPA 2024).

Score AQI	Catégorie	Code couleur	Recommandation sanitaire
0 – 50	Bon	Vert	Aucune restriction. Activités libres en extérieur.
51 – 100	Modéré	Jaune	Prudence pour les personnes hypersensibles.
101 – 150	Malsain (groupes sensibles)	Orange	Limiter les activités intenses en extérieur.
151 – 200	Malsain	Rouge	Toute la population : éviter le sport en extérieur.
201 – 300	Très malsain	Violet	Réduire au maximum les activités extérieures.
301 – 500	Dangereux	Bordeaux	Urgence sanitaire. Confinement recommandé.

3.1 Exemple de calcul — Abong-Mbang, 3 janvier 2020

Données brutes : PM_{2,5} = 53,86 µg/m³ · NO₂ = 0,29 µg/m³ · O₃ = 43,95 µg/m³ · CO = 0,351 mg/m³ · SO₂ = 0,53 µg/m³

Table 4. Calcul détaillé de l’AQI pour Abong-Mbang le 3 janvier 2020.

Polluant	Valeur	Palier EPA	Calcul	AQI partiel
PM _{2,5}	53,86 µg/m ³	Palier 3 : 35,5–55,4 → AQI 101–150	$(18,36/19,9) \times 18,36 + 101$	146
NO ₂	0,29 µg/m ³	Palier 1 : 0–100 → AQI 0–50	$\approx 0,14$	0
O ₃	43,95 µg/m ³	Palier 1 : 0–108 → AQI 0–50	$(50/108) \times 43,95$	20
CO	0,351 mg/m ³	Palier 1 : 0–4,4 → AQI 0–50	$(50/4,4) \times 0,351$	4
SO ₂	0,53 µg/m ³	Palier 1 : 0–93 → AQI 0–50	$\approx 0,28$	0
AQI FINAL = max(146, 0, 20, 4, 0)				146

Catégorie : **Malsain pour les groupes sensibles** - Polluant dominant : PM_{2,5}. Les personnes asthmatiques et âgées d’Abong-Mbang devaient limiter leurs activités en extérieur ce jour-là.

4. Ingénierie des Variables (Feature Engineering)

À partir des 18 variables météorologiques brutes, l’équipe a construit **plus de 178 features** réparties en neuf familles. Chaque feature repose sur un mécanisme physique ou statistique justifié et aucune n’est ajoutée de manière arbitraire.

Table 5. Familles de features et leur justification physique.

Famille	Nb features	Exemples et justification
Temporelles calendaires	8	Année, mois, jour de l’année, semaine, trimestre. Encodage cyclique sin/cos pour éviter la discontinuité décembre–janvier.
Saisons camerounaises	3	Saison sèche (Harmattan), transition, saison humide. <code>is_dry_season</code> , <code>is_harmattan</code> ; alignés sur les régimes de pollution.
Fourier (cycles saisonniers)	10	sin / cos pour $k = 1, 2, 3, 4, 6$ sur le jour de l’année. Permet au modèle d’extrapoler sur une année supérieure à 2026 sans voir l’année entière.
Météo dérivées	15	Amplitude thermique, fraction d’ensoleillement, intensité précipitation, composantes vectorielles du vent (u/v), flag vent calme.
Lags polluants ($\geq 7j$)	35	<code>lag7</code> , <code>lag14</code> , <code>lag21</code> , <code>lag30</code> , <code>lag60</code> pour chaque cible — en log-space, par ville strictement. Lags courts supprimés (anti-boucle).
Rolling stats polluants	28	Moyenne, écart-type, min, max sur fenêtres 7, 14, 30, 60j. Calculées avec <code>shift(1)</code> obligatoire (anti-leakage).
Lags météo	30	<code>lag1</code> , <code>lag3</code> , <code>lag7</code> , <code>lag14</code> pour température, précipitations, vent, ensoleillement. Lags courts autorisés (météo fournie par le jury).
Interactions & non-linéaires	12	<code>temp × is_dry</code> , <code>rad × sunshine_fraction</code> , <code>log1p(précipitation)</code> , terme quadratique température, ratio NO ₂ /CO.

Règle anti-leakage — appliquée à toutes les features

RÈGLE CAUSALE ABSOLUE : pour prédire un polluant au jour J , aucune feature ne peut contenir la valeur d'un polluant au jour J .

- **Lags** : uniquement `shift(lag)` avec $\text{lag} \geq 1$ (passé connu).
- **Trends** : `shift(1) - shift(N+1) = val[J - 1] - val[J - N - 1]` (jamais `val[J]`).
- **City stats** : calculées uniquement sur le jeu d'entraînement (jamais sur le test).

5. Modélisation et Apprentissage Automatique

5.1 Transformation logarithmique : une décision critique

Les distributions des polluants présentent des asymétries extrêmes : le CO atteint une skewness de 14,4, le $\text{PM}_{2,5}$ de 4,5. Sans correction, les modèles à base d'arbres consacrent l'essentiel de leur capacité à approximer les valeurs extrêmes rares. La transformation **log1p** ($\log(1 + x)$) ramène les asymétries entre $-0,09$ et $+1,05$, permettant aux modèles d'apprendre efficacement sur toute la distribution. Les prédictions sont restituées dans l'espace original par **expm1** avec troncature à zéro.

Table 6. Impact de la transformation log1p sur les distributions (asymétries réduites).

Variable	Skewness brute	Skewness log1p	Min	Médiane	Max
pm _{2,5}	4,5	0,37	0,50	20,14	972,35
pm ₁₀	4,2	0,22	0,72	31,17	1 344,95
no ₂	4,0	0,18	0,00	3,67	176,03
o ₃	1,1	-0,09	8,88	57,74	283,88
co	14,4	1,05	59,62	320,25	17 178,62
so ₂	5,1	1,82	0,00	0,90	57,25
aqi_global	1,9	0,12	11,00	72,00	500,00

5.2 Stratégie de split temporel strict

Le split temporel strict est fondamental pour les séries temporelles. Aucun split aléatoire n'est autorisé car les lags permettraient au modèle de voir des valeurs temporellement adjacentes au test. La stratégie adoptée :

Table 7. Stratégie de split temporel strict.

Phase	Période	Lignes	Rôle
Entraînement	01/01/2020 au 30/09/2024	~66 000	Apprentissage des patterns
Validation	01/10/2024 au 31/12/2024	~7 200	Sélection des hyperparamètres
Test	01/01/2025 au 20/12/2025	~14 160	Évaluation finale hors-échantillon

5.3 Algorithmes et ensemble final

Quatre algorithmes de gradient boosting ont été comparés en walk-forward cross-validation (5 folds, gap = 7 jours pour éviter la contamination des lags courts) :

Table 8. Algorithmes de l'ensemble final et leurs rôles respectifs.

Algorithme	Paramètre clé	Avantage	Rôle dans le pipeline
LightGBM	num_leaves=127, lr=0.04	Vitesse, efficacité	Algorithme de référence. GOSS + EFB pour 178 features. Base de l'ensemble final.
XGBoost	max_depth=8, lr=0.05	Robustesse	Complémentaire sur les polluants difficiles (NO ₂ , SO ₂).
CatBoost	depth=8, l2_leaf_reg=3	Catégorielles	Encodage target encoding natif pour city et région.
Ensemble pondéré	$w_a = 1/\text{RMSE}_{\text{val}}^2$	Robustesse globale	Moyenne pondérée par performance sur validation. Sélectionné par cible.

Tuning ciblé : NO₂ et SO₂

NO₂ et SO₂ bénéficient d'un tuning spécifique avec des features anthropiques (ratio NO₂/CO, interaction ville × saison sèche).

R² ≈ 0,75 sur NO₂ sans tuning et R² > 0,85 après tuning ciblé.

Les modèles sauvegardés (format .pk1) sont conservés et réutilisables pour la prédiction opérationnelle.

6. Résultats des Modèles

Table 9. Performances des 7 modèles LightGBM (espace log1p, split temporel honnête, jeu de test 2025).

Variable cible	CV R ² moyen	CV std	R ² test 2025	MAE test	RMSE test
pm _{2,5}	0,9766	±0,0284	0,9907	0,9742	1,4916
pm ₁₀	0,9572	±0,0438	0,9772	3,8060	6,7538
no ₂	0,9659	±0,0416	0,7307	1,8455	2,6707
o ₃	0,9963	±0,0021	0,8983	5,5589	8,2249
co	0,9338	±0,0776	0,9831	11,3137	22,3995
so ₂	0,8675	±0,2445	0,8008	0,3075	0,5023
aqi_global	0,9936	±0,0059	0,9750	2,9889	5,1614

7. Détection et Correction des Leakages

La correction des fuites de données (*data leakage*) a représenté l'une des contributions les plus techniques du projet. L'équipe a identifié et corrigé **trois sources distinctes** de leakage, ayant des effets significatifs sur la validité des modèles lors de l'inférence sur les données jury (sans polluants).

7.1 Leakage 1 : diff() sur les valeurs courantes

La méthode `grp.diff(7)` calcule $\text{val}[J] - \text{val}[J - 7]$, ce qui inclut $\text{val}[J]$ — la valeur que l'on cherche précisément à prédire. Lors de l'inférence sur les données du jury (qui ne contient aucun polluant), ce calcul devient impossible et retourne 0, provoquant des prédictions plates. **Cor-**

rection : `trend7_past = shift(1) - shift(8) = val[J-1] - val[J-8]`, entièrement dans le passé connu.

7.2 Leakage 2 : city_stats calculées sur tout le dataset

Les statistiques par ville calculées sur le dataset complet *avant* le split incluait des informations du futur (test set) dans le train set. **Solution :** les `city_stats` sont calculées **uniquement sur les lignes du train**, puis jointes par merge. Le test set reçoit les statistiques entraînées sur le passé uniquement.

7.3 Leakage 3 : Split aléatoire sur séries temporelles

Un split aléatoire sur des données avec lags temporels crée une fuite subtile : une observation du 15 janvier peut se retrouver dans le test, tandis que celles du 14 et 16 janvier sont dans le train. Le lag1 du test voit alors une valeur temporellement adjacente non issue du futur strict. **Solution :** `TimeSeriesSplit` strict avec `gap = 7` jours, garantissant que les lags ≥ 7 du fold de validation n'utilisent jamais les données du fold d'entraînement.

Impact des corrections : avant vs après

Avant correction : le modèle montrait $R^2 > 0,99$ en CV mais prédisait des valeurs plates ou oscillantes sur les données du jury.

Après correction complète des trois leakages : prédictions dynamiques et cohérentes physiquement sur tout horizon futur.

Le pipeline auto-régressif permet de scraper les données météo futures, prédire les polluants, et calculer l'AQI pour tout jour à venir.

8. Intervalles de Confiance : Conformal Prediction

Les prédictions ponctuelles sont assorties d'intervalles de confiance à 95 % construits par la méthode d'**Inductive Conformal Prediction (ICP)** (Papadopoulos et al., 2002). Contrairement au bootstrap, cette approche fournit une garantie mathématique de couverture marginale.

Principe en 3 étapes :

1. Calculer les scores de non-conformité sur les prédictions OOF : $s_i = |y_i - \hat{y}_i|$.
2. Déterminer le quantile empirique corrigé : $\hat{q} = \text{quantile}(\text{scores}, \lceil 0,95 \times (n + 1)/n \rceil)$.
3. Construire l'intervalle : $[\max(\hat{y} - \hat{q}, 0), \hat{y} + \hat{q}]$.

La couverture effective sur le jeu de test est mesurée *a posteriori* pour chaque modèle.

9. Pipeline de Prédiction Opérationnel

Pour les données futures du jury, le pipeline adopte une approche de **prédiction auto-régressive**, identique à celle des grands modèles NWP (Numerical Weather Prediction) comme ECMWF ou GraphCast.

Fonctionnement : Pour prédire le 21/12/2025 ($J + 1$), les lags sont calculés depuis l'historique réel ($\leq 20/12/2025$). Pour le 22/12 ($J + 2$), le lag7 reste dans le passé réel. À partir du 28/12 ($J + 8$), le lag7 utilise la prédiction de $J + 1$, le modèle s'auto-alimente. Les features météo viennent des données fournies par le jury pour les dates futures.

Dégradation attendue des performances avec l'horizon : $R^2 \approx 0,997$ à $J + 1$, $\approx 0,97$ à $J + 3$, $\approx 0,92$ à $J + 7$, comportement physiquement cohérent et conforme aux systèmes de prévision météorologique.

Workflow opérationnel : 5 étapes de la prévision en temps réel

1. **Scraping automatique** des données météo jusqu'au jour j (Open-Meteo, à partir d'une heure définie).
2. **Construction des features** (lags, rolling stats, Fourier, saisons) sur la fenêtre historique + futurs.
3. **Prédiction** de 6 polluants et de l'AQI par les modèles LightGBM sérialisés.
4. **Calcul des intervalles de confiance** (ICP 95 %).
5. **Mise à jour** de la base SQLite et déclenchement des alertes si seuils franchis.

PARTIE II — Architecture Technique de l'Application AirEka

Cette partie documente l'architecture complète de l'application web AirEka : authentification, dashboards par profil, chatbot IA, alertes email automatiques, API de prédiction et stack technologique.

10. Architecture Globale de l'Application

AirEka est une application web développée avec le framework **Plotly Dash** (Python), organisée en modules séparés par rôle utilisateur. L'architecture repose sur 9 fichiers Python principaux et une base de données SQLite.

Table 10. Modules principaux de l'application AirEka et leurs responsabilités.

Fichier	Volume	Responsabilité
app.py	~213 000 car.	Cœur : layouts, callbacks, routage, traductions (FR/EN), données simulées, carte Leaflet, thème dark/light.
citizen_pages.py	~56 000 car.	Dashboard citoyen : vue synthèse, monitoring ville, page santé, configuration alertes.
decision_maker_pages.py	~65 000 car.	Dashboard décideur : indicateurs stratégiques, carte régionale, classement villes, alertes hebdo, export PDF.
researcher_pages.py	~73 000 car.	Dashboard chercheur : benchmarks ML, simulation SHAP, statistiques avancées, export API/CSV.
email_scheduler.py	~20 000 car.	Alertes email automatiques : APScheduler, templates HTML, gestion préférences.
pdf_generator.py	~29 000 car.	Génération PDF professionnel ReportLab : couverture, KPI colorés, tableau régions, top 10 villes.
auth.py	~4 000 car.	Gestion utilisateurs : SQLite, hachage SHA-256, création / authentification / sessions.
login.py	~17 000 car.	Interface connexion/inscription : design premium, formulaires réactifs, email de bienvenue.
about_page.py	~8 000 car.	Page À propos : équipe, mentions, contacts DeepStats Consulting.

11. Système d'Authentification et Gestion des Utilisateurs

La gestion des utilisateurs est implémentée dans **auth.py** via une base de données **SQLite locale** (**users.db**). Le schéma stocke : *id*, *nom*, *email* (*unique*), *mot de passe hashé* (*SHA-256*), *rôle*, *ville*, *région*, *date de création* et *dernière connexion*.

Trois rôles distincts définissent l'expérience utilisateur : **Citoyen** (surveillance locale, alertes quotidiennes), **Décideur** (indicateurs stratégiques, alertes hebdomadaires, PDF), **Chercheur** (accès aux modèles ML, simulation, export API). À la connexion, le rôle détermine dynamiquement les onglets et fonctionnalités affichés.

Email de bienvenue à l'inscription : détails techniques

Email de bienvenue automatique : dès qu'un compte est créé avec succès, un email HTML personnalisé est envoyé.

Contenu personnalisé par rôle :

- **Citoyen** : alertes et carte temps réel.
- **Décideur** : tableau de bord stratégique et PDF.
- **Chercheur** : modèles ML et API.

Si l'envoi échoue (réseau, quota Gmail), l'inscription réussit quand même, et l'email n'est pas bloquant.

Sécurité : aucun mot de passe en clair n'est stocké. Hachage SHA-256 via `hashlib`.

12. Dashboard Principal et Système de Routage

Le fichier `app.py` constitue le cœur de l'application. Il contient cinq composants essentiels :

1. Le **dictionnaire de traductions T** : plus de 120 clés couvrant tous les textes de l'interface en français et en anglais. Le changement de langue est instantané via un callback Dash sans rechargement de page (toggle FR/EN dans la barre de navigation).
2. La **carte interactive Leaflet** (dash-leaflet) affichant les 40 villes sous forme de marqueurs colorés selon le niveau AQI. Un clic sur un marqueur ouvre un popup enrichi bilingue avec : nom de la ville, AQI coloré, badge niveau, PM_{2,5}/PM₁₀/NO₂, badge d'action (PRIORITAIRE / SURVEILLANCE / NORMAL).
3. Le **système de données** : l'application est alimentée par une API Rest (*AirEka API*) qui fournit les prévisions et données météo indispensables pour le fonctionnement.
4. Le **routage par onglets** : le callback principal `render_tab` aiguille vers la page appropriée selon le triplet (`tab_id`, `rôle`, `ville`). La liste des onglets visibles est générée dynamiquement au login selon le rôle de l'utilisateur.
5. Le **thème sombre/clair** : un toggle applique dynamiquement les variables CSS (`-bg-primary`, `-text-primary`, `-card-bg...`) sur l'ensemble de l'interface, avec mémorisation dans le Store client (`dcc.Store`).

13. Pages Spécialisées par Profil Utilisateur

13.1 Dashboard Citoyen (`citizen_pages.py`)

Le citoyen dispose de quatre onglets spécialisés :

- **Aujourd'hui** — vue synthèse : mini-sparkline AQI 7 jours, KPIs PM_{2,5}/NO₂/O₃/CO, recommandations contextuelles adaptées à la qualité du jour.
- **Ma Ville** — graphiques historiques sur 7/30 jours, évolution horaire via Plotly.
- **Santé** — recommandations médicales détaillées par niveau AQI, groupes vulnérables, protocoles d'urgence.
- **Alertes** — configuration complète des notifications email quotidiennes : heure, périmètre, activation/désactivation.

13.2 Dashboard Décideur (`decision_maker_pages.py`)

Le décideur accède à : un **tableau de bord stratégique** avec indicateurs nationaux et classement régional, une **carte de chaleur régionale** pour identifier les zones prioritaires, un **top 10 villes** les plus polluées, des **alertes hebdomadaires configurables** (périmètre : national

/ région / ville, heure, email) envoyées chaque lundi, et un bouton d'export **PDF premium** généré dynamiquement par ReportLab avec page de couverture, KPI colorés et tableau régions.

13.3 Dashboard Chercheur (researcher_pages.py)

Le chercheur dispose d'accès aux : **métriques détaillées des 7 modèles ML** (R^2 , RMSE, MAE par polluant), **graphiques SHAP** montrant l'importance des features, une **simulation interactive** permettant de modifier des paramètres météo et observer l'impact prédit sur l'AQI, corrélations météo-pollution, un **tableau comparatif multi-algorithmes**, et des fonctions d'export **CSV/API** des séries historiques et des prédictions.

14. Chatbot IA et Interprétation Contextuelle

L'application intègre un **chatbot IA contextuel (AirEka IA)** capable d'interpréter les données de qualité de l'air et de répondre aux questions des utilisateurs en langage naturel. Le chatbot dispose du contexte de la ville sélectionnée, des valeurs AQI en cours, et des tendances récentes.

Fonctionnalités du chatbot :

1. Interprétation des niveaux AQI en langage courant adapté au profil de l'utilisateur.
2. Réponses aux questions sur les polluants, leurs sources et effets sur la santé.
3. Recommandations personnalisées selon le niveau AQI et le profil (adulte sain, enfant, asthmatique, personne âgée).
4. Explications des tendances saisonnières (Harmattan, saison des pluies).

Architecture du chatbot : injection de contexte

Contexte injecté automatiquement : ville, AQI courant, polluant dominant, niveau (Bon / Modéré / Malsain / ...).

Adaptation linguistique : réponses disponibles en français et en anglais selon le toggle de langue.

Le chatbot est accessible depuis tous les dashboards (citoyen, décideur, chercheur).

15. Système d'Alertes Email Automatiques (email_scheduler.py)

Le module `email_scheduler.py` implémente un **scheduler automatique sans intervention manuelle** via **APScheduler** (`BackgroundScheduler` + `CronTrigger`). Le scheduler tourne en arrière-plan dès le lancement de l'application et surveille les préférences enregistrées dans `alert_prefs.json`.

15.1 Alertes citoyennes : quotidiennes

Chaque citoyen ayant activé les alertes reçoit **tous les jours à l'heure choisie (03h–21h)** un email HTML complet depuis `deepstats.contact@gmail.com`. Le contenu inclut : valeur AQI du jour pour sa ville, badge coloré niveau, concentrations $PM_{2,5}/PM_{10}/NO_2/SO_2$ avec indicateur seuil OMS, recommandations santé adaptées, prévisions prochains jours. L'email est envoyé *indépendamment du niveau de pollution* — le citoyen se réveille et sait immédiatement ce qu'il peut faire dehors.

15.2 Alertes décideurs : hebdomadaires (lundi 08h00)

Les décideurs reçoivent **chaque lundi matin** un rapport de tendance hebdomadaire pour le périmètre choisi (ville / région / national). Ce rapport contient : évolution AQI sur 7 jours, ville la plus et la moins polluée, KPI $PM_{2,5}$ régional, prévisions 7 jours, mesures prioritaires

selon le niveau d'urgence. Un bouton **Test immédiat** dans le dashboard permet de vérifier le fonctionnement sans attendre le lundi.

15.3 Configuration technique Gmail

Configuration Gmail : mot de passe d'application

Protocole SMTP : `smtplib.SMTP('smtp.gmail.com', 587)` avec STARTTLS.

Authentification : mot de passe d'application Google à 16 caractères (non le mot de passe principal).

Procédure : `myaccount.google.com/apppasswords` → créer → copier → insérer dans `SENDER_APP_PASSWORD`.

Fallback : si l'envoi échoue, l'exception est capturée et loggée, et l'application continue de fonctionner.

16. API de Prédiction : Architecture et Endpoints

AirEka expose une **API RESTful interne** (*AirEka API*) permettant aux chercheurs et développeurs d'interroger les prédictions de qualité de l'air programmatiquement. Cette API est implémentée directement dans le framework Dash et documentée dans le dashboard Chercheur.

Table 11. Endpoints de l'API AirEka accessible depuis le dashboard Chercheur.

Endpoint	Méthode	Description
<code>/api/predict/{ville}/{date}</code>	GET	Prédiction AQI + 6 polluants pour une ville et une date données.
<code>/api/history/{ville}</code>	GET	Historique complet des prédictions pour une ville (format JSON ou CSV).
<code>/api/regions</code>	GET	AQI agrégé par région (moyennes, rankings, tendances hebdomadaires).
<code>/api/forecast/{ville}</code>	GET	Prévisions sur 7 jours avec intervalles de confiance à 95 %.
<code>/api/export/csv</code>	POST	Export CSV personnalisé (plage de dates, villes, variables sélectionnées).

Cette API pourra être utilisée par le chercheur pour d'autres fins de recherche.

17. Stack Technologique Complète

Table 12. Stack technologique complète de l'application AirEka.

Couche	Technologie	Usage
Frontend	Plotly Dash 4.1 / React	Interface web SPA : composants réactifs, callbacks, routage.
Cartographie	dash-leaflet / OpenStreetMap	Carte interactive 40 villes avec marqueurs AQI colorés.
Backend / Scheduling	APScheduler	Jobs CRON en arrière-plan pour alertes email automatiques.
Email	smtplib + MIME	Emails HTML premium via Gmail SMTP + mot de passe d'application.
Base de données	SQLite 3	Authentification utilisateurs (<code>users.db</code>) et préférences alertes.
Génération PDF	ReportLab	Rapport PDF A4 décideur avec tableaux colorés et logos.
ML / Prédiction	LightGBM, XGBoost, CatBoost	7 modèles de prédiction. Sauvegardés sous format <code>.pkl</code> .
Collecte données	Open-Meteo + cdsapi	Scraping automatique des polluants atmosphériques.
Data manipulation	Pandas, NumPy, SciPy	Pipeline feature engineering, agrégation EPA, transformations log1p.
Sécurité	hashlib SHA-256	Hachage des mots de passe. Aucun mot de passe en clair stocké.
Chatbot IA	LLM API contextuelle	Interprétation des données, recommandations personnalisées, Q&A.

A. Tables complètes des paliers EPA

Source : US EPA, EPA-454/B-24-002, 2024.

Table 13. Paliers $\text{PM}_{2,5}$ et PM_{10} (US EPA 2024).

$C_{\min}$ ($\mu\text{g}/\text{m}^3$)	$C_{\max}$ ($\mu\text{g}/\text{m}^3$)	$\text{AQI}_{\min}$	$\text{AQI}_{\max}$	Catégorie
$\text{PM}_{2,5}$				
0,0	9,0	0	50	Bon
9,1	35,4	51	100	Modéré
35,5	55,4	101	150	Malsain (groupes sensibles)
55,5	125,4	151	200	Malsain
125,5	225,4	201	300	Très malsain
225,5	500,4	301	500	Dangereux
PM_{10}				
0	54	0	50	Bon
55	154	51	100	Modéré
155	254	101	150	Malsain (groupes sensibles)
255	354	151	200	Malsain
355	424	201	300	Très malsain
425	604	301	500	Dangereux

Table 14. Paliers NO₂, O₃, CO et SO₂ (US EPA, EPA-454/B-24-002, 2024).

$C_{\min}$	$C_{\max}$	AQI _{min}	AQI _{max}	Catégorie
NO₂ (µg/m³) — 1 heure				
0	100	0	50	Bon
101	188	51	100	Modéré
189	677	101	150	Malsain (sens.)
678	1220	151	200	Malsain
1221	2350	201	300	Très malsain
2351	5000	301	500	Dangereux
O₃ (µg/m³) — 8h glissantes				
0	108	0	50	Bon
109	138	51	100	Modéré
139	167	101	150	Malsain (sens.)
168	207	151	200	Malsain
208	393	201	300	Très malsain
394	1000	301	500	Dangereux
CO (mg/m³) — 8 heures				
0,0	4,4	0	50	Bon
4,5	9,4	51	100	Modéré
9,5	12,4	101	150	Malsain (sens.)
12,5	15,4	151	200	Malsain
15,5	30,4	201	300	Très malsain
30,5	50,4	301	500	Dangereux
SO₂ (µg/m³) — 1 heure				
0	93	0	50	Bon
94	198	51	100	Modéré
199	487	101	150	Malsain (sens.)
488	799	151	200	Malsain
800	1583	201	300	Très malsain
1584	5000	301	500	Dangereux

Références Bibliographiques

- [1] US EPA (2024). *Technical Assistance Document for the Reporting of Daily Air Quality — the Air Quality Index (AQI)*. EPA-454/B-24-002, mai 2024.
- [2] OMS (2021). *Directives mondiales relatives à la qualité de l'air*. Organisation Mondiale de la Santé, Genève.
- [3] Ke, G. et al. (2017). LightGBM: A Highly Efficient Gradient Boosting Decision Tree. *NeurIPS 2017*.
- [4] Akiba, T. et al. (2019). Optuna: A Next-generation Hyperparameter Optimization Framework. *KDD 2019*.
- [5] Papadopoulos, H. et al. (2002). Inductive Confidence Machines for Regression. *ECML 2002*.
- [6] Copernicus Atmosphere Monitoring Service (CAMS). *CAMS Global Reanalysis EAC4*. Copernicus ADS, 2024.
- [7] Open-Meteo (2024). *Air Quality API Documentation*. <https://open-meteo.com/en/docs/air-quality-api>
- [8] Plotly Technologies Inc. (2024). *Dash Documentation*. <https://dash.plotly.com>